

X 光影像胸部疾病之物件偵測

前言

胸部 X 光影像是臨床常用的篩檢工具，具有快速且低成本的優勢，可用於檢測多種胸部疾病，像主動脈硬鈣化、肺野浸潤及心臟肥大等。若這些疾病未能及時診斷與治療，可能導致嚴重後果。傳統影像判讀依賴放射科醫師，結果易受經驗與疲勞影響而產生誤判。為提升診斷效率與準確性，本研究旨在探索如何運用深度學習模型輔助醫師進行影像判讀，提供更可靠的輔助工具。

資料與方法

(1)資料來源

本實驗使用由義大醫院提供的胸部 X 光影像數據集(部分)，影像格式為 DICOM，包含正常影像及多種胸部疾病的影像資料。數據集標註了疾病類別及對應的 Bounding Box，疾病類別包括主動脈硬鈣化、肺野浸潤、心臟肥大等七種常見胸部疾病。此外，數據集分為訓練集與測試集，訓練集包含對應標註的圖像與位置信息，測試集僅包含未標註的圖像，用於模型性能評估

(2)影像前處理

一開始拿到的影像為 dicom 檔，先對其進行

I. Log Transformation


將像素值壓縮來增強低亮度區域的對比度尤其是高亮像素區域，目的為了使病灶細節更為明顯，且模擬人眼對比度的感知特性，使模型更貼合標註邏輯

II. Simplest Color Balance

統一像素亮度的範圍來減少不一致性和誤差，並提升數據的穩定

來進行 X 光的正規化


如下圖:



接著將影像的二值標註影像轉換為邊界框 (bounding box)，並計算其坐標與面積且為了防止同一病人影像出現在訓練集和驗證集中，使用病人 ID 的分割方法，以確保同一病人的影像不會同時出現在訓練集和驗證集中，最後則是將數據及轉換來符合 COCO 格式

(3)深度學習模型選用與訓練

本實驗選擇使用 Faster R-CNN 作為基礎模型，並透過遷移學習進行訓練，其中預訓練權重來自 COCO 數據集。模型訓練使用的超參數包括學習率設為 0.003，批次大小為 4，並進行 18 輪的訓練，優化器採用 SGD 搭配 Momentum 和 Nesterov 加速策略。此外，為提升模型的泛化能力，針對訓練數據進行數據增強(微微的旋轉)。模型評估則以 IoU 和 mAP 作為主要指標，用於衡量預測結果的準確性



資料分析

(1)資料增強

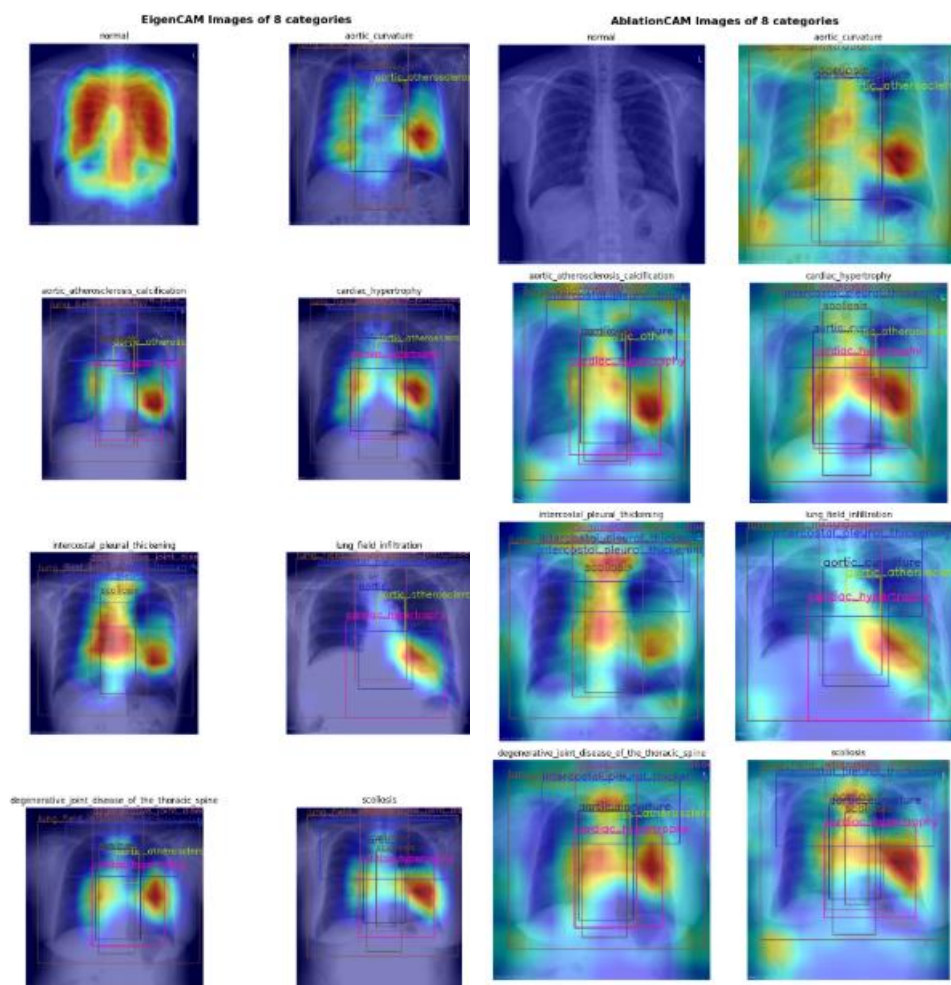
I.小角度旋轉(RandomRotation)

胸部 X 光拍攝時，病患姿勢或設備角度可能有微小差異，做+5 度的旋轉來模擬不同拍攝角度或病患略微移動

II.亮度 / 對比度 (ColorJitter)

小小地調整亮度/對比度能使模型學到在不同光照或不同病患體型(穿著厚薄)下的變化

模型結果的可視化



為了能夠更了解 Faster R-CNN 模型在判斷胸部疾病時，實際關注那些特徵區

域，我分別使用 EigenCAM 與 AblationCAM 進行可視化，如上圖

(1)EigenCAM

透過對 feature maps 進行 SVD 分解，提取比較有影響力的主成分來生成熱力圖，且以上圖的 normal 為例，熱力區主要分布在整個肺與心臟附近，而如 cardiac_hypertrophy 或 aortic_atherosclerosis_calcification 這些病症，熱區明顯偏向縱膈與心臟區域

(2)AblationCAM

逐次 ablation 特徵圖的各 channel，檢測對最終預測分數的影響，並透過影響程度來生成熱力圖，在上途中，AblationCAM 得到的紅色區塊更集中於模型真正依賴的區域，也可能出現較高對比度的分布。以 lung_field_infiltration 影像為例，紅色熱區呈現於肺野側邊緣，表示一旦遮掉該區特徵，模型對此病灶的信心即大幅下降；同時在心臟或橫膈附近可能也有局部紅區，代表模型也參考該區資訊以輔助判斷

(3)兩種方法的結論

我更傾向使用 AblationCAM，因為此方法能夠更好的展示一但某些 channel 或空間位置被移除，模型對這個病灶的預測會嚴重受影響，也就是說，可以更好的找出關鍵特徵區域

結果與討論

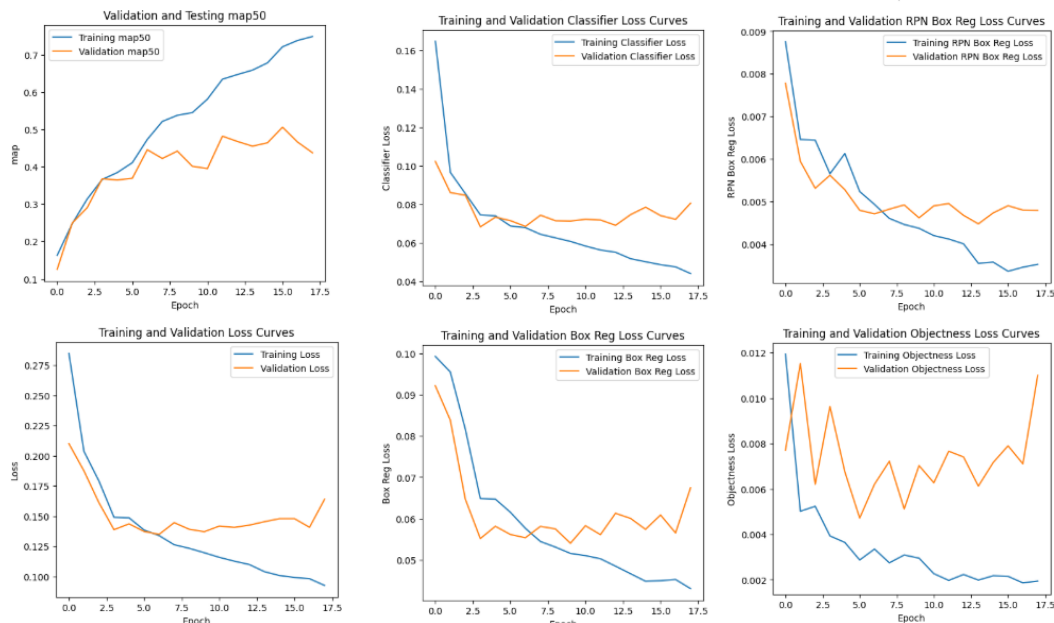
實驗以 Faster R-CNN 為基礎進行胸部 X 光影像的疾病偵測，將資料訓練至第 18 個 Epoch 後，於 Epoch16 達到最佳表現。從訓練與驗證流程來看，整體 Loss（包含 Classifier、Box Reg、RPN Box Reg、Objectness Loss）皆隨 Epoch 增加而逐漸下降；同時平均精確度 (AP) 與平均召回率 (AR) 也持續升高

最終最佳 Epoch 16 的驗證集上

```

Average Precision (AP) @[ IoU=0.50:0.95 | area= all | maxDets=100 ] = 0.257
Average Precision (AP) @[ IoU=0.50 | area= all | maxDets=100 ] = 0.506
Average Precision (AP) @[ IoU=0.75 | area= all | maxDets=100 ] = 0.218
Average Precision (AP) @[ IoU=0.50:0.95 | area= small | maxDets=100 ] = -1.000
Average Precision (AP) @[ IoU=0.50:0.95 | area=medium | maxDets=100 ] = -1.000
Average Precision (AP) @[ IoU=0.50:0.95 | area= large | maxDets=100 ] = 0.257
Average Recall (AR) @[ IoU=0.50:0.95 | area= all | maxDets= 1 ] = 0.498
Average Recall (AR) @[ IoU=0.50:0.95 | area= all | maxDets= 10 ] = 0.499
Average Recall (AR) @[ IoU=0.50:0.95 | area= all | maxDets=100 ] = 0.499
Average Recall (AR) @[ IoU=0.50:0.95 | area= small | maxDets=100 ] = -1.000
Average Recall (AR) @[ IoU=0.50:0.95 | area=medium | maxDets=100 ] = -1.000
Average Recall (AR) @[ IoU=0.50:0.95 | area= large | maxDets=100 ] = 0.499
```

且 Loss 隨 Epoch 數增加而逐漸下降，顯示模型漸趨穩定並能辨識多類胸部疾病，整體而言，Faster R-CNN 對後期 Epoch 之偵測表現有明顯提升



結論與未來展望

雖然以於 16epoch 取得最佳表現，但如果要讓模型更接近臨床應用需求，還有幾點需要加強：

I. 更好的資料增強與不平衡處理

II. 可嘗試替換不同的 backbone(例如: ResNet101、Swin Transformer)來強化特徵抽取

整體而言，此實驗已展現 Faster R-CNN 在多類胸部疾病判斷上具可行性與初步的可靠性，未來在經過適當的資料增強、模型結構優化與參數調整後，預期能進一步提升 AP 與 Recall。

備註：

I. 資料前處理:313554060(sample1)

II. 模型&可視化:31355460(sample3_sample2)